

Pipeline ETL + Análisis + Visualización con Delta Lake y Power BI

Proyecto Integrador Final — Procesamiento Big Data con Scala (IFCD0115)

Autor: [Tu Nombre Completo] **Fecha:** 14 de mayo de 2026 **Entorno:** Vía A — Azure Databricks (Runtime 16.4 LTS, Scala 2.13, Spark 3.5.2)

1. Resumen ejecutivo

Se ha construido un pipeline de datos end-to-end para una empresa ficticia de logística de última milla, **RápidoEx Logística S.L.**, que procesa diariamente envíos urbanos en cinco ciudades españolas. La solución implementa una arquitectura Medallion completa (Bronze → Silver → Gold) sobre Delta Lake en Azure Databricks, partiendo de dos fuentes en formatos distintos (CSV de 15.300 envíos y JSON de 253 repartidores), aplicando un proceso documentado de limpieza que resuelve 12 problemas de calidad de datos identificados, y entregando los resultados en un dashboard interactivo en Power BI Desktop.

Tres hallazgos más relevantes del análisis:

- Brecha entre entrega y puntualidad:** aunque el 85% de los envíos se entregan correctamente, solo el **51,9% cumple el SLA de 24 horas**. La diferencia indica que RápidoEx tiene un problema operativo de **velocidad**, no de cobertura, sobre el que la dirección puede actuar.
- Estacionalidad de Q4 en Madrid:** Madrid concentra el 40% del volumen total y muestra un pico de actividad muy marcado en octubre-noviembre (Black Friday + preparación de Navidad), información clave para el dimensionamiento de la plantilla en próximas campañas.
- Dispersión geográfica del talento:** los repartidores con mejor balance de volumen y calidad de servicio no están concentrados en Madrid (la ciudad más grande), sino distribuidos en Valencia, Sevilla y Bilbao, lo que sugiere que las ciudades pequeñas operan con **mayor eficiencia por repartidor**.

2. Dominio de negocio y preguntas

RápidoEx Logística S.L. es una empresa española de paquetería urbana fundada en 2021, con sede en Madrid y operaciones en Madrid, Barcelona, Valencia, Sevilla y Bilbao. Subcontrata para grandes marketplaces nacionales realizando la entrega final al cliente en plazos de 24-48 horas. Su flota está compuesta por 250 repartidores (mezcla de empleados y autónomos) que procesan entre 800 y 1.500 envíos diarios.

El problema de datos: la dirección de operaciones registra los envíos en un sistema de tracking y los datos de repartidores en un sistema de RRHH independiente. Nadie ha cruzado ambas fuentes para construir KPIs operativos consolidados. Como Data Engineer, mi misión es construir el pipeline que consolide ambas fuentes y entregar a dirección un dashboard ejecutivo accionable.

Preguntas de negocio que el análisis debe responder:

1. ¿Cuál es la tasa de entregas a tiempo (SLA cumplido) por ciudad y cómo evoluciona mes a mes?
2. ¿Qué 10 repartidores tienen mejor desempeño combinando volumen de entregas y puntualidad?
3. ¿En qué franjas temporales (mes, día) se concentra la mayor carga de envíos?
4. ¿Qué códigos postales y ciudades generan más incidencias?

Genial. Aquí van las secciones 36, 37 y 38. Esta es la parte más técnica del informe — donde demuestras que sabes lo que has hecho, no solo que lo has ejecutado.

Sección 36 — Arquitectura del pipeline

Pega esto en tu Word a continuación de lo anterior:


3. Arquitectura del pipeline


El pipeline implementa la arquitectura **Medallion** (también llamada Bronze-Silver-Gold), patrón estándar en lakehouses modernos. Cada capa tiene un propósito específico:

- **Bronze:** ingesta cruda de los datos tal como vienen de las fuentes, sin transformación. Sirve como copia inmutable de auditoría.
- **Silver:** capa limpia, normalizada y consolidada. Es la "fuente de verdad" sobre la que se construyen los análisis.
- **Gold:** capa agregada con KPIs de negocio pre-calculados. Optimizada para consumo por herramientas de BI.

Diagrama de flujo de datos:

FUENTES ORIGEN





Tecnologías concretas utilizadas:

- **Plataforma:** Azure Databricks Premium (Hybrid workspace), Sweden Central
 - **Cluster:** Single Node, **Standard_D4s_v3** (4 cores, 16 GB RAM), Runtime 16.4 LTS
 - **Procesamiento:** Apache Spark 3.5.2 + Scala 2.13
 - **Almacenamiento:** Delta Lake sobre Unity Catalog (catálogo **databricks_rapidoex**)
 - **Visualización:** Power BI Desktop
 - **Generación de datos sintéticos:** Python 3 + Faker (script en **datos/generar_datos.py**)
-

4. Descripción de las fuentes de datos

Para simular un escenario realista, se han generado **dos fuentes sintéticas** con dominio coherente y problemas de calidad introducidos intencionalmente. La generación es reproducible (semilla fija) y está documentada en el script `datos/generar_datos.py`.

4.1 Fuente principal: `envios.csv`

- **Formato:** CSV con cabecera, delimitador coma, codificación UTF-8
- **Volumen:** 15.300 filas (15.000 envíos únicos + 300 duplicados intencionales)
- **Periodo cubierto:** año 2024 completo
- **Distribución por ciudad:** Madrid 40%, Barcelona 25%, Valencia 15%, Sevilla 12%, Bilbao 8%
- **Estacionalidad:** picos en noviembre (Black Friday) y diciembre (Navidad)
- **Columnas:** `tracking_id`, `fecha_recogida`, `fecha_entrega`, `ciudad`, `codigo_postal`, `peso_kg`, `estado`, `repartidor_id`, `cliente_tipo`, `importe_envio`

4.2 Fuente secundaria: `repartidores.json`

- **Formato:** JSON Lines (un registro por línea)
- **Volumen:** 253 registros (250 únicos + 3 duplicados intencionales)
- **Columnas:** `repartidor_id`, `nombre`, `apellido`, `fecha_alta`, `tipo_contrato`, `ciudad_asignada`, `vehiculo`, `telefono`

4.3 Problemas de calidad introducidos

#	Problema	Fuente	Volumen	% afectado
1	Nulos en <code>peso_kg</code>	envios	459 filas	3.0%
2	Nulos en <code>fecha_entrega</code> (legítimo: envíos no entregados)	envios	2.249 filas	14.7%
3	Duplicados exactos de filas	envios	300 filas	2.0%
4	Fechas en formatos mezclados (<code>yyyy-MM-dd</code> y <code>dd/MM/yyyy</code>)	envios	1.530 filas	10.0%
5	Inconsistencias en <code>ciudad</code> (mayúsculas, espacios)	envios	1.224 filas	8.0%
6	Códigos postales con menos de 5 dígitos	envios	156 filas	4.0%
7	Pesos con coma decimal española (" <code>2,4</code> " en vez de <code>2.4</code>)	envios	199 filas	—
8	Pesos fuera de rango (negativos o > 100 kg)	envios	76 filas	0.5%

9	<code>repartidor_id</code> huérfano (FK rota)	envios	152 filas	1.0%
1	Nulos en <code>telefono</code> (no crítico)	repartidor	25	10.0%
0		es	registros	
1	Repartidores duplicados	repartidor	3	—
1		es	registros	
1	Inconsistencias en <code>tipo_contrato</code>	repartidor	15	—
2	(<code>empleado</code> , EMP, Empleado)	es	registros	

5. Decisiones de limpieza (capa Silver)

Cada uno de los 12 problemas identificados se ha tratado con una estrategia documentada y justificada técnicamente. La filosofía general ha sido **preservar al máximo la información** y solo descartar aquellos registros que no aportan valor analítico.

5.1 Eliminación (descartar el registro)

#	Problema	Decisión	Justificación	Volumen
3	Duplicados exactos	<code>dropDuplicates()</code> sobre todas las columnas de negocio	Son ruido puro, no aportan información	-289 filas
8	Pesos fuera de rango	Filtrar <code>peso_kg > 0.1 AND ≤ 50</code>	Errores claros de captura. Imputar sería ocultar un fallo del sistema fuente	-76 filas
9	FK rota en <code>repartidor_id</code>	Detección con <code>left_anti join</code> y descarte vía <code>inner join</code>	Sin repartidor real no se pueden atribuir KPIs	-152 filas
1	Repartidores duplicados	<code>dropDuplicates("repartidor_id")</code>	El ID es la clave de negocio, no debe duplicarse	-3 registros

5.2 Imputación (conservar el registro corrigiendo el valor)

#	Problema	Decisión	Justificación
1	Nulos en <code>peso_kg</code>	Imputar con la mediana (12.22 kg)	La mediana es robusta a valores extremos. Sustitución conservadora. (459 valores imputados)

5.3 Normalización (corregir el formato, no eliminar)

#	Problema	Decisión	Patrón técnico
4	Fechas mezcladas	Parseo con dos patrones combinados	<code>coalesce(to_timestamp(yyyy-MM-dd...), to_timestamp(dd/MM/yyyy...))</code>
5	Inconsistencias en ciudad	Mayúsculas + trim a forma canónica	<code>initcap(trim(col))</code> → "Madrid", "Barcelona"... (5 valores únicos)
6	Códigos postales cortos	Rellenar con ceros a la izquierda	<code>lpad(col, 5, "0")</code>
7	Pesos con coma decimal	Sustituir coma por punto	<code>regexp_replace(col, ",", ".") + cast(DoubleType)</code>
1 2	<code>tipo_contrato</code> inconsistente	Mapear variantes a forma canónica	<code>when(upper(col).isin("EMPLEADO", "EMPLEADO"), "EMPLEADO").when(...)</code>

5.4 Mantenimiento legítimo (no actuar)

#	Problema	Decisión	Justificación
2	Nulos en <code>fecha_entrega</code>	Mantener como NULL	Es semánticamente correcto: los envíos con estado INCIDENCIA o DEVUELTO no tienen fecha de entrega. Eliminarlos sesgaría los KPIs
1 0	Nulos en <code>telefono</code>	Mantener como NULL	Columna no crítica para los KPIs del proyecto

5.5 Operaciones adicionales

- **JOIN entre fuentes:** inner join `envios` ⋈ `repartidores` por `repartidor_id`, generando la tabla `silver.envios_enriquecidos` con 14.783 filas y 19 columnas.
- **Normalización de nombres:** todas las columnas convertidas a `snake_case` consistente, sin espacios.
- **Columnas derivadas:** añadidas `horas_transito` (cálculo del tiempo de entrega) y `entregado_a_tiempo` (indicador binario de SLA cumplido).
- **Auditoría:** cada registro Silver incluye `bronze_ingestion_ts` y `silver_processed_ts` para trazabilidad.

5.6 Resultado consolidado

Métrica	Valor
Filas Bronze envíos	15.300
Filas Silver envios_enriquecidos	14.783
Tasa de aprovechamiento	96,62%
Filas Silver repartidores	250
Problemas de calidad resueltos	12 / 12

6. Catálogo de KPIs

El pipeline genera **5 KPIs de negocio** organizados en dos tablas Gold con granularidades diferentes:

- `gold.kpi_envios_diarios` — granularidad día × ciudad (1.778 filas)
- `gold.kpi_repartidores` — granularidad repartidor (250 filas)

Cada KPI responde a una pregunta de negocio concreta y cumple uno o varios de los tipos exigidos por el examen (volumen, ratio, temporal, ranking).

6.1 KPI 1 — Total de envíos procesados

- **Tipo:** Volumen (conteo)
- **Definición:** número total de envíos registrados en el periodo
- **Fórmula:** `count(tracking_id)`
- **Valor 2024:** **14.783 envíos** procesados en el año completo
- **Tabla:** `gold.kpi_envios_diarios` (agregable a nivel anual)
- **Interpretación:** la operativa anual de RápidoEx se sitúa en torno a los 1.230 envíos mensuales de media, con picos de hasta 1.700 en noviembre-diciembre por estacionalidad navideña.

6.2 KPI 2 — Porcentaje de SLA cumplido

- **Tipo:** Ratio / porcentaje
- **Definición:** proporción de envíos entregados dentro del SLA de 24 horas sobre el total de envíos
- **Fórmula:** `sum(entregado_a_tiempo) / count(tracking_id) * 100`
- **Valor 2024:** **51,92%**
- **Tabla:** `gold.kpi_envios_diarios` y `gold.kpi_repartidores`

- **Interpretación:** aunque el 85% de los envíos se entrega satisfactoriamente, **casi la mitad lo hace fuera del plazo comprometido**. Es la métrica operativa más crítica y el principal punto de mejora identificado.

6.3 KPI 3 — Evolución mensual del SLA por ciudad

- **Tipo:** Temporal (serie por mes y ciudad)
- **Definición:** % SLA cumplido agregado por mes y ciudad
- **Fórmula:** `avg(pct_sla_cumplido) GROUP BY mes, ciudad`
- **Valor:** serie de 60 puntos (12 meses × 5 ciudades)
- **Tabla:** `gold.kpi_envios_diarios`
- **Interpretación:** Barcelona lidera de forma estable durante todo el año. Madrid sufre una caída relativa en los meses de mayor volumen (octubre-noviembre), lo que sugiere que **el equipo de Madrid no escala adecuadamente en campañas pico**.

6.4 KPI 4 — Top 10 repartidores por volumen y calidad

- **Tipo:** Ranking
- **Definición:** 10 repartidores con mejor combinación de volumen de envíos y porcentaje de SLA cumplido
- **Fórmula:** `score_combinado = (rank(envios_asignados desc) + rank(pct_sla desc)) / 2`, ordenado ascendente
- **Tabla:** `gold.kpi_repartidores` (con filtro de mínimo 10 envíos)
- **Interpretación:** los 10 mejores repartidores no están concentrados en Madrid sino distribuidos entre Valencia, Sevilla, Barcelona, Bilbao y Madrid, lo que indica que la productividad individual no depende del tamaño de mercado. El top performer (Prudencio Ballester, Valencia, moto) combina alto volumen y buena puntualidad.

6.5 KPI 5 — Tiempo medio de tránsito (KPI extra)

- **Tipo:** Métrica operativa adicional
 - **Definición:** media de horas transcurridas entre recogida y entrega, considerando solo envíos completados
 - **Fórmula:** `avg((fecha_entrega - fecha_recogida) en horas)`
 - **Valor 2024:** **20,45 horas de media**
 - **Tabla:** `gold.kpi_envios_diarios` y `gold.kpi_repartidores`
 - **Interpretación:** el tiempo medio está justo al borde del SLA de 24h. Cualquier desviación operativa (atascos, climatología, picos de demanda) tira fácilmente la métrica al rojo. Existe poco margen de seguridad y refuerza la conclusión del KPI 2 sobre la urgencia de optimizar tiempos.
-

7. Capturas del dashboard

El dashboard final contiene 4 visualizaciones y 2 segmentadores interactivos. A continuación se incluyen las capturas y su interpretación:

7.1 Vista global del dashboard

[INSERTAR AQUÍ CAPTURA COMPLETA DEL DASHBOARD]

Vista panorámica del dashboard operativo: tarjeta KPI principal, evolución temporal, ranking de repartidores y comparativa por ciudad, todo interconectado mediante segmentadores.

7.2 Tarjeta KPI — Envíos totales

Tarjeta de KPI principal: 14.783 envíos procesados en 2024. Sirve como cifra de referencia para contextualizar el resto de visualizaciones.

7.3 Evolución mensual del SLA por ciudad

Gráfico de líneas con una serie por ciudad. Permite identificar tendencias estacionales y comparar el desempeño relativo entre mercados. Barcelona lidera de forma consistente; Madrid presenta caídas en meses de alta carga.

7.4 Volumen total de envíos por ciudad

Gráfico de barras horizontales ordenadas. Confirma la distribución esperada del volumen: Madrid (~5.800) y Barcelona (~3.900) concentran cerca del 65% de la operativa, seguidos de Valencia, Sevilla y Bilbao.


7.5 Top 10 repartidores por volumen y calidad

Tabla filtrada por `ranking_volumen ≤ 10` que cruza datos de productividad y calidad. Muestra los repartidores que combinan más envíos con mejor cumplimiento de SLA. Útil para programas de reconocimiento interno y para detectar buenas prácticas.

7.6 Interactividad mediante segmentadores

El dashboard incluye dos segmentadores que aplican filtrado cruzado a todas las visualizaciones:

- **Segmentador por ciudad:** permite aislar el análisis para una ciudad concreta y ver cómo se comportan KPIs y rankings en ese mercado.
- **Segmentador por tipo de contrato:** permite comparar el desempeño entre empleados internos y autónomos colaboradores.



8. Conclusiones y posibles mejoras

8.1 Conclusiones principales

El proyecto demuestra que es viable construir un pipeline analítico completo de extremo a extremo en pocos días, usando tecnologías estándar de la industria (Spark, Delta Lake, Power BI) sobre infraestructura cloud (Azure Databricks). El pipeline procesa correctamente 15.300 registros, los limpia resolviendo 12 problemas de calidad documentados, los enriquece mediante un JOIN entre fuentes heterogéneas, y entrega un dashboard ejecutivo accionable.

Desde la perspectiva del **negocio simulado**, los principales hallazgos son:

1. **El cuello de botella de RápidoEx no es la cobertura, sino la velocidad:** 85% de entregas exitosas pero solo 52% dentro del SLA de 24h.
2. **Madrid concentra el volumen pero no necesariamente la eficiencia:** las ciudades pequeñas operan con mejor ratio por repartidor.
3. **La estacionalidad de Q4 estresa al equipo madrileño:** oportunidad para dimensionar refuerzos temporales en otoño.